

TRƯỜNG ĐẠI HỌC QUẢN LÝ VÀ CÔNG NGHỆ
THÀNH PHỐ HỒ CHÍ MINH

HỌC PHẦN: NHẬP MÔN TRÍ TUỆ NHÂN TẠO

BÁO CÁO ĐỀ TÀI

Ứng dụng mạng nơ-ron nhân tạo làm
hàm heuristic cho thuật toán A* trong
bài toán tìm đường mê cung

Artificial Neural Network Heuristic for A* Maze Pathfinding

Nhóm thực hiện	Tờ Linh
Thành viên	Nguyễn Quốc Minh Võ Nguyễn Tấn Tài
Sản phẩm	Source code, dataset, model, biểu đồ, demo

Mục lục

Tóm tắt	3
1 Giới thiệu	3
1.1 Bối cảnh bài toán	3
1.2 Mục tiêu đề tài	4
1.3 Câu hỏi nghiên cứu và đóng góp	4
1.4 Phạm vi thực hiện	4
2 Cơ sở lý thuyết	4
2.1 Mạng nơ-ron nhân tạo	5
2.2 Forward propagation và backpropagation	5
2.3 Epoch, loss và quá trình học	5
2.4 Training set, validation set và testing set	6
2.5 Các chỉ số đánh giá	6
2.6 BFS	6
2.7 Thuật toán A* và heuristic	7
3 Thiết kế hệ thống và thiết kế ANN	7
3.1 Tổng quan kiến trúc	7
3.2 Biểu diễn mê cung	8
3.3 Tạo dataset bằng BFS	8
3.4 Thiết kế input và output của ANN	9
3.5 Ba cấu hình ANN	9
4 Thí nghiệm	10
4.1 Môi trường và dữ liệu	10
4.2 Thí nghiệm 1: Underfitting	11
4.3 Thí nghiệm 2: Overfitting	11
4.4 Thí nghiệm 3: Good fit	12
4.5 Thí nghiệm 4: Cross-validation	12
4.6 Thí nghiệm 5: Tích hợp ANN vào A*	12
5 Kết quả	13

5.1	Kết quả huấn luyện ANN	13
5.2	Kết quả cross-validation	13
5.3	Kết quả demo tìm đường	14
6	Nhận xét	14
6.1	Phân tích underfitting	14
6.2	Phân tích overfitting	15
6.3	Phân tích good fit	15
6.4	Nhận xét về ANN heuristic	15
6.5	Hạn chế	15
6.6	Hướng phát triển	15
7	Kết luận	16

Tóm tắt

Đề tài xây dựng một hệ thống tìm đường trong mê cung bằng cách kết hợp thuật toán tìm kiếm truyền thống với mạng nơ-ron nhân tạo (Artificial Neural Network - ANN). Thay vì chỉ dùng khoảng cách Manhattan làm heuristic cho thuật toán A*, nhóm huấn luyện ANN để dự đoán chi phí còn lại từ vị trí hiện tại đến đích. Nhân huấn luyện được tạo tự động bằng BFS, vì BFS cho khoảng cách ngắn nhất thật trong mê cung dạng lưới không trọng số.

Project gồm các bước chính: sinh mê cung 20x20, tạo dataset bằng BFS, thiết kế ANN, thực hiện ba thí nghiệm underfitting, overfitting và good fit, sau đó tích hợp mô hình good fit vào A* để so sánh với BFS và A* dùng Manhattan. Kết quả thực nghiệm cho thấy mô hình good fit đạt Test MAE khoảng 2.268 bước. Trong demo cùng một mê cung, BFS duyệt 104 node, A* + Manhattan duyệt 46 node, còn A* + ANN duyệt 33 node với cùng độ dài đường đi là 20 bước.

Thông tin thực nghiệm chính

Dataset	100,000 trạng thái được sinh từ 500 mê cung ngẫu nhiên kích thước 20x20.
Input ANN	10 đặc trưng gồm tọa độ, khoảng cách tương đối đến goal và vật cản cục bộ.
Mô hình tốt nhất	Good fit, Test MSE = 14.416 và Test MAE = 2.268 bước.
Demo tìm đường	A* + ANN duyệt 33 node, ít hơn A* + Manhattan 13 node và ít hơn BFS 71 node.

Thông điệp chính

ANN không được trình bày như một phương pháp luôn thay thế hoàn toàn heuristic truyền thống. Trong đề tài này, ANN được dùng như một heuristic học từ dữ liệu để so sánh thực nghiệm với Manhattan. Vì ANN có thể dự đoán sai hoặc overestimate, nó không đảm bảo tối ưu tuyệt đối trong mọi trường hợp.

1 Giới thiệu

1.1 Bối cảnh bài toán

Tìm đường trong mê cung là một ví dụ trực quan của bài toán tìm kiếm trạng thái trong trí tuệ nhân tạo. Một tác nhân bắt đầu tại vị trí S, cần đi đến vị trí G, đồng thời tránh các ô tường. Mê cung được biểu diễn dưới dạng lưới hai chiều, mỗi ô có thể là đường đi hoặc vật cản.

Các thuật toán truyền thống như BFS và A* có thể giải quyết bài toán này. BFS đảm bảo

tìm đường ngắn nhất trong đồ thị không trọng số, nhưng thường duyệt nhiều trạng thái. A* cải thiện bằng cách dùng heuristic để ưu tiên các trạng thái có vẻ gần đích hơn. Với mê cung dạng lưới 4 hướng, heuristic Manhattan thường được dùng vì đơn giản và nhanh.

Tuy nhiên, heuristic Manhattan chỉ đo khoảng cách theo tọa độ, không trực tiếp học từ cấu trúc vật cản của dữ liệu. Vì vậy, nhóm đặt câu hỏi: có thể dùng ANN để học một heuristic từ dữ liệu đường đi thật hay không?

1.2 Mục tiêu đề tài

Đề tài tập trung vào ba mục tiêu:

1. Trình bày rõ cách ANN học, vai trò của tập train, validation, test, khái niệm epoch và các chỉ số đánh giá.
2. Thực nghiệm ba trạng thái học của mô hình: underfitting, overfitting và good fit.
3. Tích hợp ANN vào thuật toán A* như một hàm heuristic, sau đó so sánh với BFS và A* dùng Manhattan.

1.3 Câu hỏi nghiên cứu và đóng góp

Để đề tài không chỉ dừng ở việc chạy code minh họa, nhóm đặt ra các câu hỏi nghiên cứu sau:

- ANN có học được mối quan hệ giữa trạng thái mê cung và khoảng cách ngắn nhất đến goal hay không?
- Khi dùng ANN làm heuristic, A* có giảm số node phải duyệt so với BFS và A* + Manhattan trong demo hay không?
- Ba hiện tượng underfitting, overfitting và good fit có thể được thể hiện rõ qua loss curve và chỉ số MAE hay không?

Đóng góp chính của project gồm pipeline tạo nhãn tự động bằng BFS, thiết kế ba cấu hình ANN có mục đích rõ ràng, lưu lại đầy đủ mô hình/biểu đồ/kết quả thực nghiệm và xây dựng demo so sánh trực tiếp giữa thuật toán cổ điển và heuristic học từ dữ liệu.

1.4 Phạm vi thực hiện

Mê cung trong project có kích thước 20x20. Agent chỉ được đi bốn hướng: lên, xuống, trái, phải. Dữ liệu được tạo tự động từ nhiều mê cung ngẫu nhiên. ANN được huấn luyện theo bài toán hồi quy, trong đó đầu ra là khoảng cách còn lại từ ô hiện tại đến đích.

2 Cơ sở lý thuyết

2.1 Mạng nơ-ron nhân tạo

Mạng nơ-ron nhân tạo là một mô hình học máy gồm nhiều lớp tính toán. Một mạng cơ bản gồm:

- **Input layer:** nhận vector đặc trưng của dữ liệu.
- **Hidden layers:** học quan hệ phi tuyến giữa các đặc trưng.
- **Output layer:** tạo kết quả dự đoán cuối cùng.

Trong project này, ANN nhận vào 10 đặc trưng mô tả trạng thái trong mê cung và trả về một số thực biểu diễn khoảng cách còn lại đến đích.

Một neuron trong lớp ẩn thường tính:

$$z = w^T x + b, \quad a = \phi(z)$$

Trong đó x là vector đầu vào, w là trọng số, b là bias và ϕ là hàm kích hoạt. Project sử dụng ReLU ở các lớp ẩn vì hàm này đơn giản, tính nhanh và giúp mô hình học quan hệ phi tuyến tốt hơn so với chỉ dùng biến đổi tuyến tính. Lớp output không dùng softmax vì đây không phải bài toán phân loại; mô hình cần dự đoán một giá trị khoảng cách dạng số thực.

2.2 Forward propagation và backpropagation

Quá trình học của ANN có thể hiểu theo hai pha chính. Ở pha **forward propagation**, dữ liệu đi từ lớp đầu vào qua các lớp ẩn để tạo dự đoán. Dự đoán này được so sánh với nhãn thật bằng một hàm mất mát.

Ở pha **backpropagation**, sai số được truyền ngược qua mạng để tính mức độ ảnh hưởng của từng trọng số. Sau đó, thuật toán tối ưu như Adam cập nhật trọng số nhằm giảm loss ở các lần học tiếp theo.

2.3 Epoch, loss và quá trình học

Một epoch là một lần mô hình học qua toàn bộ tập training. Nếu số epoch quá ít hoặc mô hình quá nhỏ, mô hình có thể chưa học đủ quy luật của dữ liệu. Đây là underfitting. Ngược lại, nếu mô hình quá lớn và train quá lâu trên dữ liệu hạn chế, mô hình có thể ghi nhớ dữ liệu train thay vì học quy luật tổng quát. Đây là overfitting.

Đồ thị loss qua các epoch là công cụ quan trọng để quan sát quá trình học:

- Train loss và validation loss đều cao: mô hình có thể underfit.
- Train loss giảm mạnh nhưng validation loss tăng hoặc dao động xấu: mô hình có thể overfit.

- Train loss và validation loss cùng giảm rồi ổn định: mô hình có xu hướng fit tốt hơn.

2.4 Training set, validation set và testing set

Dữ liệu được chia thành ba phần:

- **Training set:** dùng để cập nhật trọng số của ANN.
- **Validation set:** dùng để theo dõi mô hình trong quá trình học và chọn cấu hình.
- **Testing set:** dùng để đánh giá cuối cùng sau khi đã chọn mô hình.

Trong project, tỉ lệ chia là 70/15/15. Validation set cần tách khỏi testing set để tránh việc mô hình hoặc người thiết kế vô tình điều chỉnh cấu hình theo kết quả test. Khi đó, test không còn phản ánh khách quan khả năng tổng quát của mô hình.

2.5 Các chỉ số đánh giá

Với bài toán phân loại, một số chỉ số thường gặp gồm:

- **Accuracy:** tỉ lệ dự đoán đúng trên tổng số mẫu.
- **ROC/AUC:** khả năng phân biệt giữa các lớp ở nhiều ngưỡng quyết định.
- **Cross-validation:** cách chia dữ liệu thành nhiều fold để đánh giá độ ổn định.

Trong project này, ANN dự đoán khoảng cách còn lại, nên đây là bài toán hồi quy. Do đó, nhóm sử dụng:

- **MSE:** sai số bình phương trung bình, phạt mạnh các dự đoán sai nhiều.
- **MAE:** sai số tuyệt đối trung bình, dễ diễn giải vì đơn vị là số bước.

Hai chỉ số được tính theo công thức:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad \text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Trong đó y_i là khoảng cách thật do BFS tạo ra và $\hat{y}_i$ là khoảng cách do ANN dự đoán. MSE nhạy hơn với lỗi lớn, còn MAE dễ dùng khi thuyết trình vì có thể diễn giải trực tiếp là “mô hình sai trung bình bao nhiêu bước”.

Ví dụ, $\text{MAE} = 2.268$ nghĩa là mô hình dự đoán sai trung bình khoảng 2.268 bước.

2.6 BFS

BFS duyệt đồ thị theo từng lớp khoảng cách từ điểm bắt đầu. Trong mê cung không trọng số, BFS đảm bảo tìm được đường ngắn nhất nếu tồn tại đường đi. Nhược điểm là BFS không dùng thông tin hướng đến goal nên có thể duyệt nhiều trạng thái.

Trong project, BFS có hai vai trò:

1. Tạo nhãn `true_distance` cho dataset.
2. Là thuật toán baseline trong demo so sánh.

2.7 Thuật toán A* và heuristic

A* đánh giá mỗi trạng thái bằng công thức:

$$f(n) = g(n) + h(n)$$

Trong đó:

- $g(n)$: chi phí đã đi từ start đến node hiện tại.
- $h(n)$: chi phí ước lượng từ node hiện tại đến goal.
- $f(n)$: tổng chi phí dự đoán.

Heuristic Manhattan được tính bằng:

$$h(n) = |x - x_g| + |y - y_g|$$

Với lưới 4 hướng không trọng số, Manhattan là heuristic đơn giản, nhanh và thường hiệu quả. Ý tưởng của đề tài là thay $h(n)$ bằng $h_{\text{ANN}}(n)$, tức giá trị dự đoán từ mạng ANN.

Vai trò của heuristic trong đề tài

Heuristic không trực tiếp tạo đường đi. Nó chỉ quyết định thứ tự ưu tiên mở rộng node trong A*. Nếu heuristic gần với khoảng cách thật, A* thường duyệt ít node hơn. Nếu heuristic sai nhiều, thuật toán có thể duyệt thừa node hoặc mất tính đảm bảo tối ưu nếu heuristic overestimate.


3 Thiết kế hệ thống và thiết kế ANN

3.1 Tổng quan kiến trúc

Hệ thống được chia thành các module rõ ràng:

- `maze.py`: sinh mê cung và xử lý ô lưới.
- `search.py`: cài đặt BFS, A* và Manhattan heuristic.
- `dataset.py`: sinh dataset có nhãn bằng BFS.
- `features.py`: chuyển trạng thái mê cung thành vector đặc trưng.

- `models.py`: định nghĩa ba cấu hình ANN.
- `train.py`: train underfit, overfit và good fit.
- `demo.py`: so sánh BFS, A* + Manhattan và A* + ANN.



Hình 1: Pipeline tổng quát của project

3.2 Biểu diễn mê cung

Mê cung là ma trận 20x20:

```

0 = duong di
1 = tuong / vat can
S = diem bat dau
G = diem dich
  
```

Agent có thể đi bốn hướng. Một bước di chuyển giữa hai ô kề nhau có chi phí bằng 1.

3.3 Tạo dataset bằng BFS

Với mỗi mê cung ngẫu nhiên, hệ thống chọn một goal rồi chạy BFS từ goal để tính khoảng cách ngắn nhất đến mọi ô reachable. Nhờ chạy BFS từ goal, ta thu được nhãn cho nhiều trạng thái trong cùng một lần duyệt.

Quy trình tạo dataset:

1. Sinh 500 mê cung ngẫu nhiên kích thước 20x20.
2. Với mỗi mê cung, chọn goal hợp lệ.
3. Dùng BFS tính khoảng cách thật từ mọi ô reachable đến goal.
4. Trích xuất tối đa 200 trạng thái mỗi mê cung.
5. Lưu thành file `data/maze_dataset.csv`.

Dataset thu được có 100,000 dòng.

Bảng 1: Thông số dataset và cách chia dữ liệu

Thành phần	Giá trị sử dụng trong project
Số mê cung sinh dữ liệu	500 mê cung
Kích thước mỗi mê cung	20x20 ô
Tỉ lệ tường khi sinh ngẫu nhiên	0.25
Số mẫu tối đa mỗi mê cung	200 trạng thái reachable
Tổng số dòng dataset	100,000 dòng
Tỉ lệ train/validation/test	70% / 15% / 15%

3.4 Thiết kế input và output của ANN

Mỗi mẫu dữ liệu tương ứng với một trạng thái trong mê cung. Vector input gồm 10 đặc trưng:

Bảng 2: Các đặc trưng đầu vào của ANN

Đặc trưng	Ý nghĩa
x, y	Tọa độ hiện tại của agent, đã chuẩn hóa theo kích thước mê cung.
goal_x, goal_y	Tọa độ điểm đích, đã chuẩn hóa.
dx, dy	Khoảng cách tuyệt đối theo hai trục giữa vị trí hiện tại và goal.
up_wall	Ô phía trên là tường hoặc nằm ngoài biên.
down_wall	Ô phía dưới là tường hoặc nằm ngoài biên.
left_wall	Ô bên trái là tường hoặc nằm ngoài biên.
right_wall	Ô bên phải là tường hoặc nằm ngoài biên.

Output của ANN là:

```
true_distance = so buoc ngan nhat tu o hien tai den goal
```

Đây là bài toán hồi quy vì mô hình dự đoán một giá trị số thực.

Nhóm chọn các đặc trưng đầu vào theo hướng vừa đủ cho một mô hình nhập môn: tọa độ cho biết vị trí tuyệt đối, dx/dy giữ lại thông tin gần giống Manhattan, còn bốn biến tường lân cận cung cấp tín hiệu về vật cản xung quanh. Cách thiết kế này giúp báo cáo dễ giải thích và đủ để minh họa ý tưởng heuristic học từ dữ liệu.

3.5 Ba cấu hình ANN

Nhóm thiết kế ba mô hình để minh họa ba hiện tượng học.

Bảng 3: Thiết kế các mô hình ANN

Mô hình	Cấu hình	Mục đích
Underfit	Dense(4) + output, 5 epoch	Mạng quá nhỏ, học chưa đủ.
Overfit	Dense(512), Dense(512), Dense(256), Dense(128), output, 150 epoch, chỉ dùng 3,000 dòng train	Mạng lớn và train lâu trên ít dữ liệu để tạo overfitting.
Good fit	Dense(64), Dropout(0.2), Dense(32), Dense(16), output, EarlyStopping	Mạng vừa phải, có kiểm soát overfitting.

Cả ba mô hình dùng optimizer Adam, loss MSE và metric MAE. Mô hình good fit dùng cơ chế dừng sớm theo `val_loss` để dừng khi validation loss không cải thiện.

Nguyên tắc thiết kế mô hình

Underfit và overfit được cố ý thiết kế để minh họa hai lỗi học máy thường gặp. Mô hình good fit mới là cấu hình chính dùng cho demo. Cách bố trí này giúp báo cáo thể hiện đầy đủ quá trình thử nghiệm: không chỉ đưa ra mô hình tốt nhất, mà còn giải thích vì sao các cấu hình khác chưa phù hợp.

4 Thí nghiệm

4.1 Môi trường và dữ liệu

Project được thực hiện bằng Python, TensorFlow/Keras, NumPy, Pandas và Matplotlib. Dataset gồm 100,000 dòng, chia thành:

- 70,000 dòng train.
- 15,000 dòng validation.
- 15,000 dòng test.


Riêng thí nghiệm overfitting chỉ dùng 3,000 dòng train để làm hiện tượng học quá mức rõ hơn.

Bảng 4: Mục tiêu kiểm chứng của từng thí nghiệm

Thí nghiệm	Mục tiêu	Dấu hiệu cần quan sát
Underfitting	Kiểm tra trường hợp mô hình quá đơn giản.	Train loss và validation loss còn cao, MAE chưa tốt.
Overfitting	Kiểm tra trường hợp mô hình quá phức tạp trên ít dữ liệu.	Train loss giảm nhưng validation loss xấu hơn hoặc dao động.
Good fit	Tìm cấu hình cân bằng hơn để dùng làm heuristic.	Validation loss ổn định, test MAE tốt nhất trong ba mô hình.
Cross-validation	Kiểm tra độ ổn định qua nhiều lần chia dữ liệu.	MAE giữa các fold không chênh lệch quá lớn.
Demo A*	Đánh giá tác động của ANN khi thay heuristic.	So sánh độ dài đường đi, số node duyệt và thời gian chạy.

4.2 Thí nghiệm 1: Underfitting


Mô hình underfit được thiết kế rất nhỏ và chỉ train 5 epoch. Kỳ vọng là mô hình không đủ năng lực học quan hệ giữa trạng thái mê cung và khoảng cách thật. Dấu hiệu cần quan sát là loss còn cao và MAE chưa tốt.



Hình 2: Đồ thị loss và MAE của mô hình underfit

4.3 Thí nghiệm 2: Overfitting


Mô hình overfit có nhiều layer và nhiều neuron hơn, nhưng chỉ train trên 3,000 dòng dữ liệu. Mục tiêu là quan sát việc train loss tiếp tục giảm trong khi validation loss không cải thiện tương ứng, thậm chí tăng hoặc dao động mạnh.



Hình 3: Đồ thị loss và MAE của mô hình overfit

4.4 Thí nghiệm 3: Good fit

Mô hình good fit dùng kiến trúc vừa phải, có Dropout và EarlyStopping. Cấu hình này nhằm giảm overfitting và đạt khả năng tổng quát tốt hơn trên tập test.



Hình 4: Đồ thị loss và MAE của mô hình good fit

4.5 Thí nghiệm 4: Cross-validation

Để kiểm tra độ ổn định, nhóm chạy 5-fold cross-validation với mô hình good fit. Mỗi fold dùng 20,000 dòng làm validation và phần còn lại làm train. Kết quả trung bình giúp đánh giá mô hình ít phụ thuộc hơn vào một lần chia dữ liệu.

4.6 Thí nghiệm 5: Tích hợp ANN vào A*

Sau khi train, mô hình good fit được xuất thành định dạng TensorFlow Lite tại `models/ann_heuristic_goodfit.tflite`. Khi A* cần tính $h(n)$, hệ thống chuyển trạng thái hiện tại thành vector input rồi thông qua `tf.lite.Interpreter` để suy luận (dự đoán khoảng cách còn lại).

So sánh ba thuật toán:

- BFS: không dùng heuristic.

- A^* + Manhattan: dùng khoảng cách Manhattan.
- A^* + ANN: dùng mô hình ANN làm heuristic.

5 Kết quả

5.1 Kết quả huấn luyện ANN

Bảng 5: Kết quả test của ba mô hình ANN

Mô hình	Train	Val	Test	Epoch	Test MSE	Test MAE
Underfit	70,000	15,000	15,000	5	16.253	2.619
Overfit	3,000	15,000	15,000	150	22.276	2.747
Good fit	70,000	15,000	15,000	15	14.416	2.268

Mô hình good fit đạt Test MAE thấp nhất, khoảng 2.268 bước. Mô hình overfit tuy lớn hơn và train lâu hơn nhưng test MAE kém hơn, cho thấy việc tăng độ phức tạp không tự động làm mô hình tốt hơn.

Kết quả nổi bật

So với underfit, mô hình good fit giảm Test MAE từ 2.619 xuống 2.268 bước, tương đương cải thiện khoảng 13.4%. So với overfit, good fit cũng tốt hơn khoảng 17.4% theo MAE. Điều này củng cố nhận xét rằng mô hình vừa phải, có regularization và dừng sớm phù hợp hơn với dataset của project.


5.2 Kết quả cross-validation

Bảng 6: Kết quả 5-fold cross-validation

Fold	Validation rows	MAE	MSE
1	20,000	2.245	15.241
2	20,000	2.292	15.139
3	20,000	2.208	14.751
4	20,000	2.206	14.018
5	20,000	2.465	14.373
Trung bình	-	2.283	14.704

MAE trung bình 2.283 cho thấy mô hình có sai số tương đối ổn định qua nhiều fold. Fold 5 có MAE cao hơn một chút, có thể do tập validation trong fold đó chứa nhiều trạng thái khó hơn.

5.3 Kết quả demo tìm đường



Hình 5: So sánh đường đi của BFS, A* + Manhattan và A* + ANN

Bảng 7: Kết quả so sánh thuật toán trên cùng một mê cung

Thuật toán	Tìm thấy	Độ dài	Node duyệt	Thời gian
BFS	Có	20	104	0.10 ms
A* + Manhattan	Có	20	46	0.07 ms
A* + ANN	Có	20	34	0.37 ms

Trong demo này, cả ba thuật toán đều tìm được đường dài 20 bước. A* + Manhattan duyệt ít node hơn BFS. A* + ANN duyệt ít node nhất, cho thấy heuristic học từ dữ liệu có thể giúp thuật toán ưu tiên hướng tìm kiếm tốt hơn trong trường hợp cụ thể.

Về số node duyệt, A* + ANN giảm khoảng 68.3% so với BFS và khoảng 28.3% so với A* + Manhattan trong mê cung demo. Độ dài đường đi vẫn giữ ở 20 bước, tức trong trường hợp này việc dùng ANN heuristic không làm đường đi dài hơn.

Mặc dù A* + ANN có thời gian chạy hơi nhỉnh hơn một chút so với tính toán biểu thức Manhattan thuần túy do quá trình xử lý của mô hình, nhưng nhờ áp dụng TensorFlow Lite, tốc độ inference trên CPU diễn ra cực kỳ nhanh (chỉ 0.37ms). Điều này chứng minh tiềm năng áp dụng AI vào thuật toán tìm đường trong các bài toán thực tế mà không lo nghẽn cổ chai về mặt tính toán.

6 Nhận xét

6.1 Phân tích underfitting

Mô hình underfit có số tham số rất ít và chỉ train 5 epoch. Dù loss giảm nhanh ở các epoch đầu, sai số test vẫn còn cao. Điều này phù hợp với kỳ vọng: mô hình chưa đủ năng lực biểu diễn quan hệ giữa vị trí, vật cản cục bộ và khoảng cách thật.

6.2 Phân tích overfitting

Mô hình overfit có số tham số lớn hơn rất nhiều và train 150 epoch trên tập train nhỏ. Đồ thị cho thấy train loss tiếp tục giảm, nhưng validation loss tăng hoặc dao động rõ. Đây là dấu hiệu mô hình học quá kỹ dữ liệu train, dẫn đến khả năng tổng quát kém hơn.

6.3 Phân tích good fit

Mô hình good fit có kiến trúc vừa phải, thêm Dropout và EarlyStopping. Kết quả test tốt nhất trong ba mô hình với MAE khoảng 2.268 bước. Điều này cho thấy việc kiểm soát độ phức tạp và theo dõi validation loss quan trọng hơn việc chỉ tăng kích thước mô hình.

6.4 Nhận xét về ANN heuristic

ANN heuristic giúp A* duyệt ít node hơn trong demo, nhưng không nên kết luận ANN luôn tốt hơn Manhattan. Manhattan có ưu điểm đơn giản, nhanh và có tính chất lý thuyết tốt trong lưới 4 hướng. ANN có thể học thêm thông tin từ dữ liệu, nhưng cũng có thể dự đoán sai.

Điểm quan trọng khi bảo vệ là: đề tài không khẳng định ANN thay thế hoàn toàn A*. ANN chỉ thay phần heuristic để tạo một biến thể A* + ANN và so sánh bằng thực nghiệm.

Khi thuyết trình, nên nhấn mạnh sự khác nhau giữa hai loại đánh giá. MAE đánh giá chất lượng dự đoán khoảng cách của ANN trên dataset, còn số node duyệt đánh giá tác động của heuristic trong thuật toán A*. Một mô hình có MAE tốt thường có ích cho A*, nhưng hai chỉ số này không hoàn toàn tương đương vì A* còn phụ thuộc vào thứ tự ưu tiên node và cấu trúc cụ thể của mê cung.

6.5 Hạn chế

- Input của ANN chỉ quan sát bốn ô lân cận, chưa nhìn được toàn bộ cấu trúc mê cung.
- ANN heuristic không đảm bảo admissible, nên không đảm bảo luôn tìm đường tối ưu trong mọi trường hợp.
- Quá trình tích hợp TensorFlow Lite yêu cầu thêm bước export mô hình và thiết lập interpreter, làm tăng độ phức tạp của code.
- Dataset được sinh ngẫu nhiên, chưa bao phủ hết mọi dạng mê cung khó.

6.6 Hướng phát triển

- Mở rộng input thành cửa sổ 3x3 hoặc 5x5 quanh agent để ANN thấy nhiều vật cản hơn.

- Train trên nhiều mê cung hơn và kiểm thử trên các mê cung có cấu trúc đặc biệt.
- Thử nghiệm suy luận trên các phần cứng chuyên dụng như Neural Processing Unit (NPU) hoặc Edge TPU.
- So sánh thêm với Greedy Best-First Search hoặc các biến thể heuristic khác.

7 Kết luận

Đề tài đã xây dựng một pipeline hoàn chỉnh từ sinh dữ liệu, huấn luyện ANN đến tích hợp vào thuật toán tìm kiếm. BFS được dùng để tạo nhãn khoảng cách thật, ANN học cách dự đoán chi phí còn lại, và mô hình good fit được dùng làm heuristic cho A^* .

Kết quả thực nghiệm chứng minh được ba hiện tượng học quan trọng của ANN: underfitting, overfitting và good fit. Trong demo tìm đường, $A^* + ANN$ duyệt ít node nhất trên mê cung được chọn, cho thấy heuristic học từ dữ liệu có tiềm năng hỗ trợ thuật toán tìm kiếm truyền thống.

Tuy nhiên, ANN heuristic không đảm bảo tối ưu tuyệt đối như các heuristic có tính chất lý thuyết rõ ràng. Vì vậy, kết quả phù hợp nhất nên được hiểu là một minh họa cho sự kết hợp giữa AI hiện đại và thuật toán cổ điển, đồng thời là cơ sở để tiếp tục cải tiến mô hình và cách tích hợp.